2: Tidy data

Videregående kvantitative metoder i studiet af politisk adfærd

Frederik Hjorth adjunkt, Ph.D. fh@ifs.ku.dk fghjorth.github.io @fghjorth

Institut for Statskundskah Københavns Universitet

13. september 2018

- 1 Opsamling fra sidst
- 2 Tidy data
- 3 Piping
- 4 Øvelse
- 5 Kig fremad

Leeper, Really Introductory Introduction:

- Getting started
 - brug af R som regnemaskine: fx. (2+4)/7
 - parsing errors ctr. syntax errors
 - nye vektorer: fx. dice <- c(2,2,3,4)
 - ekstrahering fra vektorer: fx. dice[1:3]
 - ny data frame: fx. df <- data.frame(dice,number=1:4)
 - data framens struktur: str(df)
 - centrale tendenser: summary(df)

Opsamling fra sidst

OOOO

Leeper

Real data

Opsamling fra sidst

O O O O

Leeper

- installer pakker: install.packages()
- indlæs pakker: library()
- importér data: import() fra rio-pakken

- Randomness
 - sample fra en vektor: sample()
- Plots

Opsamling fra sidst

OOOOO

Leeper

- pakke: ggplot2
- fx.ggplot(iris,aes(x=Sepal.Length)) + geom_histogram

Basic programming tools

- funktioner: fx. ftoc <- function(f) { c<-((f-35)*5)/9 ; print(c) }
- for loops: fx. for (i in 1:10) print(i*i)

Opsamling fra sidst

OOO
O

Leeper

DataCamp: Introduction to the Tidyverse


- 1: Data wrangling
 - gapminder-datasættet
 - 'filter'
 - 'arrange'
 - 'mutate'
- 3: Grouping and summarizing
 - 'summarize'
 - 'group_by'

Opsamling fra sidst

○○○●

DataCamp øvelse

Tænkeren bag 'tidy data': Hadley Wickham




i alt forfatter til ≈ 63 R-pakker (a.k.a. 'hadleyverse' eller 'tidyverse')

Den nye generation af R-udviklere:



Et typisk data science workflow:



Program

Centrale Hadley-pakker til databehandling:

- ggplot2 (visualisering)
- dplyr (databehandling)
- tidyr (omformning)
- readr (import af csv o. lign.)
- purrr (funktioner og loops)
- tibble (smartere version af data frames)
- stringr (behandling af character-objekter)
- forcats (faktorer)
- → alle disse kan loades samtidig med library(tidyverse)



Andre nyttige hadleyverse-pakker:

- haven (import af data fra Stata, SPSS etc.)
- readxl (Excel-filer)
- rvest (web scraping)
- httr (API'er)
- lubridate (dato-objekter)

Den hyppigste, mest tidskrævende form for tidying: 'nørkling' med data

head(salary.selected)

##		name	depar	rtment_name	total.earnings
##	1	Abadi,Kidani A	Assessing	Department	\$46,591.98
##	2	Abasciano, Joseph	Boston Police	Department	\$97,579.88
##	3	Abban, Christopher John	Boston Fire	Department	\$124,623.25
##	4	Abbasi, Sophia	Gre	een Academy	\$18,249.83
##	5	Abbate-Vaughn, Jorgelina	BPS Ellis	Elementary	\$85,660.28
##	6	Abberton, James P	Public Works	Department	\$50,337.63

		treatmenta	treatmentb
Messy data:	John Smith	_	2
Messy data:	Jane Doe	16	11
	Mary Johnson	3	1

	person	treatment	result
	John Smith	а	_
	Jane Doe	а	16
Tidy data:	Mary Johnson	а	3
	John Smith	b	2
	Jane Doe	b	11
	Mary Johnson	b	1

Principper i tidy data:

- Hver variabel udgør en kolonne
- A Hver observation udgør en række
- Hver enhed udgør en tabel

NB: good for data entry \neq tidy \rightarrow det typiske datasæt er messy!

Endnu et eksempel på messy ctr. tidy:

TABLE 1"Messy" data on video game sales and review scores. Sales data from VGChartz; review data from Metacritic. Data set sourced from Rush Kirubi, via Kaggle (bit.ly/2KNZgM9).

Publisher 82.53 Score = 8. Wii Sports Nintendo Score = 76. Count = 51 Count = 322 Mario Kart Nintendo 35.52 Score = 82 Score = 8.3. Wii Count = 73 Count = 709 32.77 Score = 80. Score = 8. Wii Sports Nintendo Resort Count = 73 Count = 192 **New Super** Nintendo 29.80 Score = 89 Score = 8.5. Mario Bros. Count = 65 Count = 431 Wii Plav Nintendo 28.92 Score = 58. Score = 6.6. Count = 41 Count = 129

TABLE 2 "Tidy" data on video game sales and review scores

	TABLE 2 "Tidy" data on video game sales and review scores.				
).		Publisher	Global sales (million units)		
	Wii Sports	Nintendo	82.53	Critic	76
	Wii Sports	Nintendo	82.53	User	80
	Mario Kart Wii	Nintendo	35.52	Critic	82
	Mario Kart Wii	Nintendo	35.52	User	83
	Wii Sports Resort	Nintendo	32.77	Critic	80
	Wii Sports Resort	Nintendo	32.77	User	80
-	New Super Mario Bros.	Nintendo	29.80	Critic	89
	New Super Mario Bros.	Nintendo	29.80	User	85
+	Wii Play	Nintendo	28.92	Critic	58
	Wii Play	Nintendo	28.92	User	66

 $Kilde: \verb|https://rss.onlinelibrary.wiley.com/doi/abs/10.1111/j.1740-9713.2018.01169.x| \\$


De fire verber i databehandling:

- filter: udvælg observationer
- 2 transform: tilføje eller omkode variable
- 3 aggregate: opsummere værdier til én eller færre
- 4 sort: ændre observationers rækkefølge
- → vi kan foretage (næsten) al databehandling med dplyr

Implementering af de fire verber i dplyr:

	verbum	funktion i dplyr
1	filter	filter() til rækker, select() til kolonner
2	transform	<pre>mutate()</pre>
3	aggregate	<pre>group_by() og summarise()</pre>
4	sort	arrange()

Uvurderligt opslagsværk til databehandling: data wrangling cheat sheet



ligger også på fagets hjemmeside under extras



Ceci n'est pas un pipe.



Data: datasættet i pakken 'gapminder'

```
> gapminder
# A tibble: 1.704 x 6
              continent vear lifeExp
  country
                                           pop ddpPercap
   <fct>
              <fct>
                        <int> <db1>
                                         <int>
                                                   < db7 >
  Afghanistan Asia
                         1952
                                 28.8 8425333
                                                     779
  Afghanistan Asia
                         1957
                                       9240934
                                                     821
  Afghanistan Asia
                         1962
                                                     853
                                 32.0 10267083
  Afghanistan Asia
                         1967
                                 34.0 11537966
                                                     836
  Afghanistan Asia
                         1972
                                 36.1 13079460
                                                     740
  Afghanistan Asia
                         1977
                                 38.4 14880372
                                                     786
  Afghanistan Asia
                         1982
                                 39.9 12881816
                                                     978
  Afghanistan Asia
                         1987
                                                     852
                                 40.8 13867957
  Afghanistan Asia
                         1992
                                 41.7 16317921
                                                     649
  Afghanistan Asia
                         1997
                                 41.8 22227415
                                                     635
# ... with 1,694 more rows
>
```

https://youtu.be/Z8t4k0Q8e8Y?t=54s

Vi ønsker at gøre flg.:

- gruppér observationerne efter land
- 2 udregn gennemsnitslevetid og medianindbyggertal over hele perioden for hvert land
- 3 reducér til lande m. mere end 10M indbyggere
- 4 sortér efter land (omvendt alfabetisk) og gennemsnitslevetid

Klodset løsning I: Gem hvert skridt i et nyt objekt (\rightarrow rod)

```
by_country <- group_by(gapminder, country)</pre>
country sum <- summarize(by_country,avglifeexp=mean(lifeExp),</pre>
                                       medianpop=median(pop))
big_countries <- filter(country_sum, medianpop > 10000000)
result1 <- arrange(big_countries, desc(country), avglifeexp)</pre>
```

Pining 0000000

Klodset løsning II: Skriv funktionerne indlejret (nested) i hinanden (\rightarrow totalt ulæseligt)

```
result2 <-
  arrange(
    filter(
      summarize(
        group_by(gapminder,
                 country
        avglifeexp=mean(lifeExp).
        medianpop=median(pop)
      medianpop > 10000000
    desc(country),
    avglifeexp
```

Smart løsning: brug pipede funktioner (\rightarrow enkelt, letlæseligt)

```
result3 <- gapminder %>%
group by(country) %>%
summarize(avglifeexp=mean(lifeExp),
medianpop=median(pop)) %>%
filter(medianpop > 10000000) %>%
arrange(desc(country), avglifeexp)
```

Piping 000000

bemærk; den originale data frame 'pipes' ned gennem funktionerne, så angives kun én gang



»This directory contains data on nearly 3 million tweets sent from Twitter handles connected to the Internet Research Agency, a Russian "troll factory" and a defendant in an indictment filed by the Justice Department in February 2018, as part of special counsel Robert Mueller's Russia investigation. (...) The basis for the Twitter handles included in this data are the November 2017 and June 2018 lists of Internet Research Agency-connected handles that Twitter provided to Congress. This data set contains every tweet sent from each of the 2,752 handles on the November 2017 list since May 10, 2015.«

Kilde: https://github.com/fivethirtyeight/russian-troll-tweets

- hent et af datasættene fra https://github.com/fivethirtyeight/russian-troll-tweets
- vad er de hyppigste og næsthyppigste sprog?
- 3 i hvilken region har trolde flest følgere?
- 4 hvilket sprog retweetes oftest?
- **5** hvor ofte nævnes hhv. Trump og Clinton i tweetsne?

Næste gang: Data fra online-kilder

- screen scraping
- API'er
- pensum: MRMN kap. 9+14
- vigtigt i kap. 9: 9.1.10+
- case: Hjorth (ananas i egen juice \leadsto eksempel på data fra online-kilder, læs kursorisk)
- ekstra hiemmearbeide: lav en twitter API kev

Tak for i dag!